

# Методология сравнения предсказания слов у людей и больших языковых моделей в cloze-тесте

Монина Вера Евгеньевна | 02.06.2026 | Научный руководитель: Выренкова Анастасия Сергеевна<sup>1</sup>

## 1. Постановка задачи

- Предсказуемость слова — одна из ключевых динамических переменных в психолингвистике: чем слово предсказуемее, тем короче время фиксации, меньше вероятность регрессий при чтении.
- Стандартный инструмент сбора норм — **cloze-тест** (Taylor 1953): участнику предъявляется левый контекст, он называет наиболее вероятное следующее слово. *Cloze-вероятность* = доля участников, назвавших слово  $x$ .
- Проблема: сбор норм трудозатратен. Вопрос: можно ли заменить людей LLM?
- Теория surprisal (Hale 2001; Levy 2008): когнитивная нагрузка пропорциональна  $-\log_2 P(\text{слово} \mid \text{контекст})$ .
- LLM-surprisal предсказывает время чтения и амплитуду N400.
- Предыдущие подходы сравнивали точечные предсказания (1–3 ответа от модели). Ключевое ограничение: точечное предсказание не отражает структуру неопределенности модели.
- Новизна настоящей работы: сравниваются **полные вероятностные распределения на трёх уровнях** — лексическом, морфосинтаксическом, семантическом. Также проводился анализ предсказуемости целевого слова.

## 2. Данные

- Корпус: **Russian Sentence Corpus** (Laurinavichyute et al. 2019) — 144 адаптированных предложения из НКРЯ.
- Нормы cloze-теста людей: **6 705** предсказаний, 1–63 уникальных ответа на контекст.
- Баланс целевых слов: длина (3–10 знаков) × частотность (высокая / низкая) × POS (существительные 72 / прилагательные 36 / глаголы 36).
- Разметка всех предсказаний: **Stanza + PyMorphy3**. Фильтр `is_russian` исключает предсказания с орфографическими ошибками и случайные наборы символов.

## 3. Методология

### 3.1 Модели

- **GPT-4o-mini** — мультиязычная модель OpenAI, zero-shot через API.
- **Llama 3.1 (8B)** — открытая мультиязычная авторегрессионная модель, которая тестировалась локально. Выбор обусловлен: (а) полная воспроизводимость; (б) меньший масштаб — проверка, не зависят ли эффекты от размера модели.

### 3.2 Модифицированный beam search

Проблема: обычный beam search отсекает гипотезы по score — нельзя получить полное распределение. Авторегрессионная модель выдаёт вероятности на уровне токенов, а не слов.

Предложенное решение — **beam search без отсечения**:

- Алгоритм стартует из левого контекста и итеративно расширяет все активные ветви, накапливая логарифмы вероятностей токенов.
- Ветвь завершается при появлении границы слова (пробел, пунктуация) или при глубине  $> 8$  токенов.
- Итоговая вероятность кандидата:
$$P(\text{слово}) = \exp(\sum \log\text{-prob токенов пути})$$
- После поиска: дедупликация по нормализованной форме + фильтрация по `is_russian`.

Полученные данные от каждой модели:

- GPT: **2–1 067** уникальных кандидатов на контекст. Средняя длина слова  $\approx 3$  токенов

<sup>1</sup> Отдельная благодарность выражается Олегу Серикову, Андрею Пихтину и Наталье Анатольевне Слюсарь

- Llama: генерация ограничена кириллическими токенами (эффективность + исключение нерелевантных продолжений). Предсказывается **107–577** кандидатов на контекст.

### 3.3 Метрика анализа предсказуемости целевого слова

Вопрос: как различается распределения вероятностей целевых слов у людей и моделей?

- Для каждого контекста считается вероятность целевого слова  $p_{human}$  и  $p_{model@k}$  (относительно  $top-k$  множества предсказаний, отсортированных по убыванию вероятности).
- Контексты разбивались на 4 группы относительно “угадываемости” контекста.

### 3.4 Метрики — лексический уровень

Вопрос: какую долю ответов людей покрывают  $top-k$  предсказания модели?

- Формируются два множества:  $L_{human}$  (уникальные ответы людей) и  $L_{model@k}$ .
- Метрика  **$overlap@k$** :  

$$overlap@k = |L_{human} \cap L_{model@k}| / |L_{human}|$$
- Сравнение по поверхностным формам и по леммам — разница показывает вклад морфологической вариативности.
- Анализируется динамика: быстрое плато → концентрированное распределение; монотонный рост → равномерное распределение.

### 3.5 Метрики — синтаксический уровень

Вопрос: совпадают ли грамматические ожидания модели и людей?

- Для каждого контекста строятся взвешенные по вероятности POS-распределения (например, {NOUN: 0.70, VERB: 0.20, ADJ: 0.10}).
- **$POS\_intersection@k$**  — доля совпавших тегов среди  $k$  наиболее вероятных у людей и у модели. При  $k=1$ : совпадает ли самая ожидаемая часть речи?
- **Корреляция POS-распределений** по каждому тегу для 144 контекста: высокий  $r$  означает, что модель концентрирует вероятность на данном теге в тех же контекстах, что и люди.
- Аналогичный анализ для морфологических признаков: падеж, число, род, одушевлённость, вид, время, форма глагола (разметка Stanza).

### 3.6 Метрики — семантический уровень

Вопрос: насколько близки семантические пространства предсказаний?

- Каждое предсказание переводится в статистический эмбединг при помощи word2vec модели (ruwikiruscorpora).
- **Centroid Similarity** — косинусное сходство между центроидами облаков предсказаний людей и модели.
- **Precision / Recall / F1** на основе ближайшего соседа:
  - Recall: для каждого ответа людей ищется ближайший сосед среди  $top-k$  модели; ответ «покрыт», если сходство  $> \theta$ . Recall = сумма вероятностей покрытых ответов.
  - Precision: симметрично — насколько предсказания модели семантически близки к ответам людей.
  - Анализ при  $\theta \in \{0.80, 0.90, 0.95\}$ .

### 3.7 Анализ контекста

- **Энтропия Шеннона** по предсказаниям людей:  $H = -\sum p_i \ln p_i$ . Низкая  $H \rightarrow$  закрытый контекст (люди сходятся); высокая  $H \rightarrow$  открытый (широкий разброс). Контексты разбиты на квартили Q1–Q4.
- **Предсказуемость морфологических признаков целевого слова**: доля предсказаний, совпадающих с признаком целевого слова (падеж, число, род и др.), усреднённая по контекстам.

## 4. Результаты

### 4.1 Уровень целевого слова

### 1. Люди vs GPT

- Корреляция между вероятностями целевого слова у людей и у GPT-4o-mini по всем 144 контекстам составляет  $r = 0.881$  ( $p < 0.001$ ) по Пирсону и  $\rho = 0.755$  ( $p < 0.001$ ) по Спирмену.
- В **C1** средние вероятности практически совпадают (0.398 vs 0.378) - GPT не только «угадывает» целевое слово, но и присваивает ему сопоставимую вероятность.
- **C2** (только люди): средняя  $p\_human = 0.099$  - это контексты с низкой, но ненулевой вероятностью. **C3** представлен лишь 2 контекстами - GPT почти не «фантазирует» сверх человеческого распределения.
- 60% контекстов — класс **C4**: в большинстве случаев целевое слово не восстанавливается однозначно ни людьми, ни моделью.

### 2. Люди vs Llama

- Корреляция между вероятностями целевого слова у людей и у Llama составляет  $r = 0.423$  ( $p < 0.001$ ) по Пирсону и  $\rho = 0.594$  ( $p < 0.001$ ) по Спирмену.
- Число контекстов в **C1** почти такое же, но средняя  $p\_model = 0.031$ : модель формально включает целевое слово в распределение, но оно не находится среди наиболее вероятных предсказаний.
- **C3** у Llama значительно шире, однако средняя  $p\_model = 0.002$ .

| Тип контекста                            | Кол-во контекстов | Ср. $p\_human$ | Ср. $p\_model$ GPT | Кол-во контекстов | Ср. $p\_human$ | Ср. $p\_human$ Llama |
|------------------------------------------|-------------------|----------------|--------------------|-------------------|----------------|----------------------|
| <b>C1</b> : Предсказали и люди, и модель | 34                | 0.398          | 0.378              | 33                | 0.388          | 0.0306               |
| <b>C2</b> : Только люди                  | 22                | 0.099          | 0.00               | 23                | 0.097          | 0.00                 |
| <b>C3</b> : Только модель                | 2                 | 0.00           | 0.092              | 11                | 0.00           | 0.0021               |
| <b>C4</b> : Никто                        | 86                | 0.00           | 0.00               | 77                | 0.00           | 0.00                 |

## 4.2 Лексический уровень (overlap@k)

- GPT: быстрое достижение плато уже при  $k=20$  (~25%). **Распределение концентрированное.** Добавление менее вероятных кандидатов почти не добавляет пересекающихся слов.
- Llama: монотонный рост вплоть до  $k=400$  (49%). **Распределение разреженное.** Зато при больших  $k$  Llama обгоняет GPT по % перекрытия множества ответов людей.
- **Лемматизированный overlap > поверхностного** у обеих моделей: часть расхождений — результат морфологическая вариативность.
- Вывод: модели не охватывает более 50% лексического пространства людей.

| k   | GPT (лемма) | GPT (форма) | Llama (лемма) | Llama (форма) |
|-----|-------------|-------------|---------------|---------------|
| 5   | 0,216       | 0,200       | 0,073         | 0,059         |
| 20  | 0,251       | 0,236       | 0,204         | 0,172         |
| 100 | 0,258       | 0,238       | 0,406         | 0,340         |
| 400 | 0,259       | 0,238       | 0,490         | 0,436         |

## 4.3 Синтаксический уровень

- GPT в **69%** случаев предсказывает **самую ожидаемую часть речи людей** — практически применимый результат для предварительной оценки стимулов.
- При  $k=3$  GPT и Llama, практически, сходятся в результатах (~51% vs ~51%); при  $k=5$  Llama немного лучше (49,6% vs 37,2%).

| POS_intersection@1 |       |       |
|--------------------|-------|-------|
| Разметчик          | GPT   | Llama |
| Stanza (UPOS)      | 59,7% | 36,8% |
| PyMorphy3          | 68,8% | 37,5% |

- GPT чувствителен к контекстам, в которых могут встречаться **служебные части речи**:  $r=0,83$  для ADP. У Llama эти корреляции ближе к 0 — модель не улавливает, когда контекст «требуется» предлог или союз.
- Для **существительных** GPT линейная корреляция умеренная (0,69), но ранговая высокая (0,83) — ранжирование контекстов сохраняется хорошо, хотя абсолютные вероятности могут отличаться.
- Для **глаголов и прилагательных** GPT также превосходят вторую модель.
- Если рассматривать отдельно финитные формы от нефинитных, то GPT существенно превосходит Llama в предсказании и инфинитива ( $r = 0,733$  vs  $0,553$ ), и финитных форм ( $r = 0,660$  vs  $0,387$ ).
- **Причастия и деепричастия**:  $r \approx 0$  или отрицательные у обеих моделей.

| Корреляция POS-распределений (Пирсон $r$ / Спирмен $\rho$ ) |                 |             |                 |              |
|-------------------------------------------------------------|-----------------|-------------|-----------------|--------------|
| Тег                                                         | GPT $r$         | GPT $\rho$  | Llama $r$       | Llama $\rho$ |
| NUM                                                         | 0,937           | 0,616       | 0,898           | 0,226        |
| ADP                                                         | 0,830           | 0,408       | 0,002           | 0,136        |
| SCONJ                                                       | 0,761           | 0,400       | 0,031           | 0,373        |
| NOUN                                                        | 0,693           | 0,825       | 0,194           | 0,305        |
| VERB                                                        | 0,556           | 0,629       | 0,416           | 0,524        |
| ADJ                                                         | 0,529           | 0,385       | 0,121           | 0,181        |
| PRTF/PRTS / GRND                                            | $\approx 0 / -$ | $\approx 0$ | $\approx 0 / -$ | $\approx 0$  |

- GPT лучше предсказывает большинство **именных категорий**. Особенно высокие результаты обнаруживаются для косвенных падежей, где левый контекст жестко задает управление: Ins  $r=0,846$ ; Loc  $r=0,832$ ; Dat  $r=0,792$ . Корреляция с именительным падежом ниже ( $r=0,198$ ), так как он менее синтаксически определен.
- **Время глагола** — единственный признак, где Llama превосходит GPT (0,429 vs 0,256). Возможное объяснение: более широкое распределение Llama случайно покрывает нужные временные формы чаще.

| Морфологические признаки (средний $r$ по признаку) |              |                |
|----------------------------------------------------|--------------|----------------|
| Признак                                            | GPT mean $r$ | Llama mean $r$ |
| Одушевлённость                                     | 0,699        | 0,184          |
| Род                                                | 0,667        | 0,246          |
| Падеж                                              | 0,613        | 0,372          |
| Аспект                                             | 0,556        | 0,362          |
| Число                                              | 0,491        | 0,212          |
| Время глагола                                      | 0,256        | 0,429          |

#### 4.4 Семантический уровень

- Семантический центр GPT-предсказаний близок к центру предсказаний людей (0,70 при top-100). У Llama перекрытие значительно слабее (0,37). Рост у обеих моделей замедляется после top-5: **семантическое ядро пространства определяют наиболее вероятные кандидаты**.

| Centroid Similarity |       |       |
|---------------------|-------|-------|
| top-k               | GPT   | Llama |
| 1                   | 0,574 | 0,269 |
| 5                   | 0,688 | 0,353 |
| 100                 | 0,702 | 0,370 |

- **GPT: высокий Precision (0,60) + умеренный Recall (0,39):** большинство предсказаний модели семантически близки к ответам людей, но охватывают лишь ~39% семантического разнообразия людей.
- Llama при top-100: **Recall возрастает до 0,49** (обгоняет GPT), но **Precision падает до 0,04** — модель «разбрасывает» предсказания широко, среди них случайно оказываются близкие к людским, но большинство — нерелевантны.
- F1: GPT  $\approx$  0,43; Llama  $\approx$  0,06. Ни одна модель не воспроизводит семантическое разнообразие человеческих предсказаний в полной мере.

| Precision / Recall / F1 ( $\theta = 0,90$ ) |            |           |             |            |
|---------------------------------------------|------------|-----------|-------------|------------|
| Модель                                      | Recall @10 | Prec. @10 | Recall @100 | Prec. @100 |
| GPT-4o-mini                                 | 0,386      | 0,599     | 0,396       | 0,595      |
| Llama 3.1                                   | 0,218      | 0,057     | 0,489       | 0,041      |

#### 4.5 Влияние энтропии контекста

- В Q1 (закрытых контекстах) люди в среднем дают только ~7 разных ответов; в Q4 — 38. Чем более открытый контекст, тем больше человеческих ответов оказывается за пределами любого модельного распределения.
- GPT: в Q1 плато достигается уже при  $k = 10$  ( $0,425 \rightarrow 0,435$ ) — **концентрированное распределение хорошо захватывает закрытые контексты**. В Q4 перекрытие низкое даже при  $k = 100$  ( $0,126$ ).
- Llama: в Q1 при  $k = 100$  достигает **0,584** — **лучший результат**. Широкое распределение полезно именно в закрытых контекстах, где нужно найти нужную лексему среди сотен кандидатов.

| Квартиль / $H_{\text{mean}}$ | Mean кол-во ответов | GPT @10 | GPT @100 | Llama @10 | Llama @100 |
|------------------------------|---------------------|---------|----------|-----------|------------|
| Q1 $H \approx 1,06$          | 6,8                 | 0,425   | 0,435    | 0,243     | 0,584      |
| Q2 $H \approx 1,97$          | 10,9                | 0,284   | 0,288    | 0,157     | 0,427      |
| Q3 $H \approx 2,49$          | 17,9                | 0,168   | 0,185    | 0,085     | 0,361      |
| Q4 $H \approx 3,20$          | 38,3                | 0,102   | 0,126    | 0,045     | 0,255      |

| Квартиль / $H_{\text{mean}}$ | Примеры контекстов                                                                 |
|------------------------------|------------------------------------------------------------------------------------|
| Q1 $H \approx 1,06$          | 1) Дорога ведёт в глухой ____<br>2) Причиной аварии был мобильный ____             |
| Q2 $H \approx 1,97$          | 1) Приготовь себе диетические овощные блюда, ____<br>2) В котёл бросают куски ____ |
| Q3 $H \approx 2,49$          | 1) В деревнях по-прежнему ____<br>2) Вспоминая ____                                |
| Q4 $H \approx 3,20$          | 1) Тому, кто ____<br>2) В речи учёного прозвучало ____                             |

#### 4.6 Предсказуемость морфологических признаков целевого слова

- **Люди превосходят обе модели по всем признакам:** люди лучше предсказывают морфологические признаки целевого слова.
- Падеж — самое интересное расхождение между моделями: Llama (0,417) лучше GPT (0,282), хотя в корреляционном анализе GPT лидировал.
- GPT точнее по глагольным категориям (вид, время).

| Признак        | Люди  | GPT   | Llama |
|----------------|-------|-------|-------|
| Число          | 0,706 | 0,588 | 0,609 |
| Падеж          | 0,699 | 0,282 | 0,417 |
| Одушевлённость | 0,652 | 0,344 | 0,368 |
| Время          | 0,643 | 0,419 | 0,291 |
| Род            | 0,539 | 0,363 | 0,392 |
| Вид            | 0,495 | 0,425 | 0,299 |

## 5. Выводы

- Новая методология (beam search без отсечения) впервые позволяет эффективно **сравнивать полные вероятностные распределения**, а не точечные предсказания.
- **Лексический и семантический уровни:** полная замена людей невозможна. F1 GPT  $\approx 0,43$ ; перекрытие при  $k \leq 49\%$ ; даже в закрытых контекстах покрытие не превышает 58%. Значительная часть человеческого лексического и семантического пространства не перекрывается моделями.
- **GPT пригоден для предварительного ранжирования стимулов:**  $r=0,88$  с `r_human` позволяет надёжно различать лёгкие и трудные контексты по предсказуемости целевого слова (что остается ключевым назначением cloze-теста).
- **Морфосинтаксический уровень:** GPT в 69% случаев угадывает ожидаемую часть речи и демонстрирует высокие корреляции с человеческими ответами на уровне падежей (косвенные падежи  $r > 0,79$ ), рода, числа, вида. Данная модель применима для первичной оценки грамматических ожиданий.
- Системная слабость обеих моделей: **причастия и деепричастия** — наиболее низкая корреляция с людьми.
- GPT vs Llama: **GPT точнее при малых k и по грамматике; Llama при больших k покрывает больше человеческих предсказаний**, но с низкой точностью. Это отражает принципиально разную стратегию: концентрированное vs разреженное распределение.
- **Энтропия контекста — значимый предиктор:** закрытые контексты лучше покрываются моделями; в открытых контекстах человеческое разнообразие шире модельного распределения.

## 6. Перспективы

- Добавить монолингвальные русские модели (ruGPT-3.5 и аналоги).
- Расширить стимулы: в ходе создания корпуса собирались нормы не только для позиции целевого слова, но и для остальных слов в предложениях. Рассмотреть разные синтаксические конструкции, разную длину видимого контекста, перебалансировать стимулы по разным параметрам.
- Исследовать зависимость от формулировки промпта, т.к. современные модели чувствительны к инструкции.
- Провести ручную разметку контекстов для более тонкого анализа.

## 7. Избранная литература

- Hale, J. (2001). A probabilistic Earley parser as a psycholinguistic model. Proceedings of NAACL 2001.

- Laurinavichyute, A. K., Sekerina, I. A., Alexeeva, S., et al. (2019). Russian Sentence Corpus: Benchmark measures of eye movements in reading in Russian. *Behavior Research Methods*, 51, 1161–1178.
- Levy, R. (2008). Expectation-based syntactic comprehension. *Cognition*, 106(3), 1126–1177.
- Taylor, W. L. (1953). Cloze procedure: A new tool for measuring readability. *Journalism Quarterly*, 30, 415–433.

## 8. Доступ к результатам и коду



<https://github.com/VeraMonina/KR3>